

Dissertation

Delsad, Sebastien, DS

Arnold, Melvin, MX

Logean, Romain, SIQ

**Projet SHS de 1ère année master : Etude
des conditions d'émergence de l'altruisme
par le biais de simulations informatiques**

Professeur: Christian Sachse

Philosophie des sciences de la vie

Date de soumission : 04.06.2025

Lausanne, année académique 2024-2025

The logo of the École Polytechnique Fédérale de Lausanne (EPFL) is displayed in a bold, red, sans-serif font. The letters are stylized, with the 'E' and 'F' having a distinctive blocky appearance.

Contents

1	Introduction	1
2	Cadre théorique [1]	1
2.1	Altruisme biologique	1
2.2	Altruisme comportemental	2
2.3	Altruisme psychologique	3
2.4	Lien entre définitions	4
2.5	Lien à la théorie des jeux	4
2.6	Travaux connexes	5
3	Méthodologie : Simulation informatique de l'altruisme	6
3.1	Présentation du modèle de simulation	6
3.1.1	Définition de l'environnement	6
3.1.2	Introduction des agents	8
3.2	Paramètres de simulation et apprentissage de l'agent autonome	8
3.3	Hypothèses et limites du modèle	9
4	Résultats	11
4.1	Problèmes rencontrés	11
4.2	Agent intelligent vs semi-aléatoire	11
4.2.1	Agent intelligent vs giving	11
4.2.2	Agent intelligent vs attacking	12
4.3	Agent intelligent vs aléatoire	13
4.4	Semi-aléatoire contre aléatoire	13
4.4.1	Giving vs aléatoire	13
4.4.2	Attacking vs aléatoire	14
4.4.3	Complet vs aléatoire	14
4.5	Semi-aléatoire contre semi-aléatoire	14
4.5.1	Complet vs giving vs attacking	14
5	Discussion : Pertinence et implications des résultats	15
5.1	Analyse des résultats	15
5.1.1	Paramètres variés	15
5.1.2	Agent intelligent vs semi-aléatoire	15
5.1.3	Semi-aléatoire vs aléatoire	17
5.1.4	Semi-aléatoire vs semi-aléatoire	18
5.2	Liens entre altruisme biologique, comportemental et psychologique	18
5.3	Critique de la méthodologie	20
6	Conclusion	20

1 Introduction

L'altruisme est une notion complexe qui intrigue autant les biologistes que les psychologues et les philosophes. Dans son ouvrage *Je t'aide... moi non plus*, Christine Clavien propose trois définitions distinctes de l'altruisme : biologique, comportemental et psychologique. Ces définitions reflètent des perspectives différentes mais complémentaires, chacune relevant d'un domaine spécifique. L'altruisme biologique se concentre sur l'impact des comportements sur la fitness (succès reproductif) des individus, l'altruisme comportemental se définit par des actes observables visant à bénéficier à autrui, tandis que l'altruisme psychologique met en avant les intentions et motivations internes des individus. Selon l'auteur, malgré leurs différences, ces trois notions d'altruisme se croisent sans pour autant se recouper. En effet, l'altruisme biologique pourrait bien être une condition nécessaire à l'évolution de l'altruisme psychologique, signifiant que ces notions seraient liées sans être identiques.

Ces trois formes d'altruisme, en apparence distinctes, ne convergent-elles pas vers une même réalité sous-jacente? Cette question est fondamentale pour mieux comprendre les comportements altruistes tels qu'ils se manifestent dans la nature et chez les humains. Si ces trois définitions trouvent une cohérence commune, cela pourrait unifier des débats encore fragmentés entre disciplines, en reliant la biologie évolutive, les sciences comportementales et la psychologie.

Historiquement, la question de l'altruisme s'inscrit dans un débat remontant aux travaux de Darwin, pour qui la coopération posait un paradoxe à la théorie de la sélection naturelle. Cette tension a nourri des théories comme la sélection de parentèle (Hamilton), l'altruisme réciproque (Trivers) et plus récemment les modèles de théorie des jeux qui explorent la stabilité évolutive des comportements altruistes. Effectivement, pour évaluer l'émergence de la coopération et le concept de stratégie évolutionnairement stable, les théoriciens utilisent également la théorie des jeux pour modéliser les interactions entre individus égoïstes et coopératifs. Ainsi, l'utilisation de simulations informatiques pour tester un exemple spécifique permet de dépasser les limites de l'observation empirique et d'apporter un éclairage inédit sur les dynamiques évolutives et cognitives de l'altruisme.

Des comportements altruistes peuvent-ils exister ? Si oui, dans quels environnements peuvent-ils émerger ? Voici les principaux questionnements qui seront traités au cours de cette étude, par le biais de simulations informatiques, dans le but de discuter des différentes définitions de l'altruisme.

Tout d'abord, le cadre théorique est exposé; les différentes définitions de l'altruisme sont discutées. Ensuite, la méthodologie utilisée pour la simulation informatique est explicitée, avant de présenter les résultats obtenus. Finalement, la pertinence des résultats est discutée et la méthodologie est critiquée, afin de répondre à la problématique de ce travail.

2 Cadre théorique [1]

2.1 Altruisme biologique

Le paradoxe de l'altruisme biologique et l'émergence de la coopération représentent un défi fondamental en biologie évolutionnaire. L'altruisme est défini comme un comportement qui augmente la valeur sélective (fitness) d'un autre individu, tout en réduisant celle de l'individu qui adopte ce comportement. Une telle définition semble à première vue incompatible avec les principes de la sélection naturelle. En effet, si un comportement nuit à la fitness de l'individu altruiste, il paraît improbable que la sélection naturelle favorise la transmission des bases génétiques sous-tendant ce comportement. Ainsi, un tel comportement ne devrait pas être préservé au fil des générations. Pourtant, dans le monde vivant, les comportements altruistes sont fréquemment observés, ce qui en fait un véritable paradoxe empirique.

Pour mieux comprendre ce paradoxe, on peut considérer une population composée d'individus altruistes et d'individus non-altruistes. Dans ce cas, la fitness des altruistes est forcément inférieure à celle des non-altruistes, car ces derniers bénéficient des actions altruistes sans en payer les coûts. Par conséquent, la proportion de non-altruistes augmente à chaque génération par rapport à celle des altruistes. En itérant ce processus sur plusieurs générations, on parvient à la disparition complète des individus altruistes. Cette logique semble impliquer que l'altruisme ne peut pas se maintenir dans une population.

Cependant, plusieurs théories ont été développées pour résoudre ce paradoxe en réévaluant les concepts de sélection, de fitness et de coopération. Parmi celles-ci, la théorie de l'altruisme réciproque, proposée par Robert Trivers, joue un rôle central. Cette théorie postule qu'un individu peut adopter un comportement altruiste envers un autre si ce dernier est susceptible de rendre la pareille à l'avenir, assurant ainsi un bénéfice mutuel à long terme. Bien que ce cadre conceptuel repose sur des interactions répétées, il permet d'expliquer la persistance de certains comportements altruistes dans des contextes où la réciprocité est possible.

La théorie de l'altruisme réciproque a également donné naissance à des développements majeurs en biologie évolutionnaire, notamment à la théorie des jeux appliquée à l'évolution. En modélisant les interactions sociales comme des jeux stratégiques, cette approche permet d'explorer les conditions sous lesquelles la coopération et l'altruisme peuvent émerger et se stabiliser dans des populations. Ces théories enrichissent notre compréhension des mécanismes évolutifs et montrent que, loin d'être un paradoxe insurmontable, l'altruisme peut s'inscrire sans problèmes dans le cadre de la sélection naturelle, notamment à travers des dynamiques complexes de coopération.

2.2 Altruisme comportemental

Le modèle économique néoclassique repose sur la figure de l'homo oeconomicus, un agent rationnel doté de désirs et d'objectifs propres, qui cherche en toutes circonstances à maximiser son profit et son bien-être personnel, selon ses préférences individuelles. Ce modèle postule que les agents économiques sont toujours capables de prendre les décisions les plus optimales possibles. Cependant, il a fait l'objet de nombreuses critiques. Certains auteurs, comme Gerd Gigerenzer, ont en effet démontré que, dans plusieurs cas, suivre son intuition et ses émotions se révèle, en moyenne, plus avantageux que d'agir systématiquement de manière rationnelle.

En réponse à ces limites, des chercheurs opposés à la théorie économique néoclassique ont fondé l'économie expérimentale, une approche qui mobilise les techniques issues de la psychologie expérimentale afin de tester empiriquement la validité des théories économiques existantes. Cette discipline a permis de définir une forme spécifique d'altruisme, qualifiée d'altruisme comportemental. Selon cette conception, une action est dite altruiste si elle implique un coût pour l'agent qui l'accomplit, procure un bénéfice à autrui, et ne permet pas à l'agent d'espérer un retour sur investissement, que ce soit immédiat ou différé. Le « coût » se réfère souvent à des pertes en ressources, comme de l'argent ou du temps.

L'altruisme comportemental se distingue de l'altruisme biologique, si bien que certains comportements jugés altruistes par les biologistes ne le sont pas selon les économistes expérimentaux, et inversement. Pour étudier ces comportements, les économistes expérimentaux ont recours à des expériences sous forme de jeux, comme le *Trust Game* ou le *Dictator Game*. Cependant, ces expérimentations sont réalisées sur des périodes de temps limitées, ce qui empêche de mesurer avec précision les effets potentiellement bénéfiques de certaines actions altruistes sur le long terme. Cette restriction peut limiter la compréhension globale du phénomène.

Une manifestation notable de l'altruisme comportemental mise en évidence lors de ces expériences est celle de la punition altruiste. Il a été observé que les participants, lorsqu'ils en ont la possibilité, punissent des joueurs opportunistes, et ce, malgré le coût personnel que cela peut représenter. De manière empirique, ces punitions ont également un effet comportemental; les in-

dividus opportunistes tendent à devenir plus altruistes après avoir été sanctionnés. Par ailleurs, le simple fait de savoir que leurs actions soient observées peut influencer le comportement des joueurs.

Contrairement aux hypothèses des économistes néoclassiques, les comportements altruistes, bien qu'ils semblent parfois coûteux à court terme, se révèlent souvent optimaux sur le long terme. En outre, ils peuvent être bénéfiques à des niveaux autres que celui de l'individu, notamment pour des groupes ou encore dans un cadre génétique, renforçant ainsi l'importance de l'altruisme dans des contextes plus larges.

2.3 Altruisme psychologique

La notion d'altruisme psychologique s'inscrit au cœur d'un débat philosophique ancien et toujours d'actualité entre les partisans de l'égoïsme psychologique et ceux de l'altruisme psychologique. Les défenseurs de l'égoïsme psychologique soutiennent que les êtres humains sont intrinsèquement motivés par leur propre intérêt, de sorte que toute action, même altruiste d'apparence, découlerait en réalité d'un désir égoïste. À l'inverse, les tenants de l'altruisme psychologique affirment qu'il existe des principes fondamentaux dans la nature humaine qui incitent les individus à agir dans le but de favoriser le bien-être des autres.

Les défenseurs de l'égoïsme psychologique avancent en général un argument central; toute action altruiste peut être expliquée par une motivation dirigée vers soi-même, qu'elle soit explicite ou inconsciente. En réponse, les partisans de l'altruisme psychologique proposent divers contre-arguments, parmi lesquels celui de Joseph Butler, énoncé en 1726. Butler établit un lien essentiel entre le désir et le plaisir, affirmant que le désir doit nécessairement précéder le plaisir. Par exemple, le plaisir de manger une pomme ne peut exister que s'il a été précédé par le désir de consommer cette pomme. Dès lors, le plaisir ne saurait être la motivation initiale de l'action. Cet argument remet en question l'idée selon laquelle le plaisir, en tant que quête hédoniste, serait la source première des motivations humaines. Autrement dit, si le désir d'un objet ou d'un objectif externe est indépendant d'une motivation hédoniste, alors il devient impossible d'expliquer toutes les actions humaines comme étant fondamentalement égocentriques ou orientées vers la recherche de plaisir.

Les défenseurs de l'égoïsme psychologique rétorquent en invoquant le rôle de l'inconscient dans les prises de décision. Selon eux, nos motivations profondes échappent souvent à l'introspection et pourraient être influencées par des mécanismes inconscients qui orientent nos actions vers des objectifs égoïstes.

Face à cette impasse philosophique, il est pertinent de se tourner vers les avancées scientifiques pour tenter d'éclairer ce débat. Les recherches en neurosciences ont notamment exploré les bases neuronales de l'altruisme. Certaines études révèlent que des zones spécifiques du cerveau associées à la dopamine (souvent appelée l'« hormone du plaisir ») sont fortement activées lorsque les individus pensent coopérer avec d'autres êtres humains. En revanche, ces mêmes zones sont significativement moins activées si les participants apprennent que l'interlocuteur est un ordinateur. Ces résultats semblent, à première vue, soutenir la thèse égoïste, dans la mesure où le plaisir neuronal associé à la coopération pourrait expliquer les comportements altruistes.

Cependant, les défenseurs de l'altruisme psychologique soulèvent une objection importante: peut-on réellement affirmer que l'anticipation de cette « récompense dopaminergique » est la cause première des comportements coopératifs? Cette question ramène le débat à une impasse, semblable à celle observée dans le domaine philosophique. D'autres études, notamment sur les effets des punitions et de la vengeance en tant que sources de satisfaction, n'ont pas permis de réfuter définitivement la thèse de l'altruisme psychologique.

En conclusion, et conformément à la définition de l'altruisme psychologique, il apparaît que ce débat reste irrésolu. Les approches philosophiques et scientifiques, bien qu'enrichissantes, n'ont

pas encore fourni de réponse définitive, laissant ouvertes de nombreuses pistes pour approfondir notre compréhension de la nature humaine.

2.4 Lien entre définitions

Il a été vu jusqu'ici qu'il existe plusieurs manières de définir l'altruisme. Afin de mieux comprendre le lien entre ces définitions et leurs potentielles différences, il est intéressant de les discuter et de les comparer.

Tout d'abord, les définitions de l'altruisme psychologique et comportemental sont très proches, mais apparaissent dans des contextes différents. L'altruisme comportemental apparaît principalement dans des contextes économiques où les gains sont monétaires et calculables, alors que l'altruisme psychologique apparaît plutôt dans des contextes de sciences sociales et notamment en psychologie. Dans son livre [1], Christine Clavien distingue ces différentes formes d'altruisme, mais beaucoup d'ouvrages considèrent que ces deux définitions sont équivalentes. L'altruisme psychologique s'intéresse plutôt aux intentions derrière les actions, alors que l'altruisme comportemental analyse plutôt les situations en termes de coûts et de bénéfices. Dans les deux cas, une action altruiste peut se définir simplement comme une action désintéressée qui a pour but d'aider les autres. Il existe cependant certains exemples très précis d'actions qui ne correspondent pas simultanément à ces deux définitions de l'altruisme. C'est par exemple le cas d'une situation où l'agent a une intention altruiste envers autrui, mais ne parvenant pas réellement à l'aider. D'un point de vue psychologique, cette action est considérée comme altruiste car la personne a l'intention profonde d'aider. En revanche, d'un point de vue comportemental, l'action n'est pas réellement considérée comme telle, car l'autre personne n'aura reçu aucune aide profitable. Dans la majorité des cas, ces deux définitions sont identiques.

Les similarités entre l'altruisme biologique et l'altruisme psychologique sont moins évidentes. Par exemple, le fait de donner de la nourriture empoisonnée à un mendiant, sans savoir qu'elle est toxique, est considéré comme de l'altruisme psychologique, mais pas de l'altruisme biologique ni comportemental. En effet, les motivations profondes de l'altruiste, dans ce cas, sont d'aider le mendiant, bien que biologiquement parlant, donner de la nourriture empoisonnée ne va pas favoriser les gènes du mendiant.

Cependant, en considérant la perspective géno-centrée, il existe de nombreux cas d'altruisme à la fois psychologique, comportemental et biologique. Effectivement, selon cette perspective, il est possible d'affirmer que lorsqu'on a la réelle motivation d'aider quelqu'un et qu'on y parvient, c'est à la fois de l'altruisme psychologique, comportemental et biologique, à condition que cette autre personne soit proche génétiquement.

Pour tenter de mieux comprendre le lien entre les différents types d'altruisme, il est pertinent de prendre une autre perspective. Au lieu de partir de leurs définitions respectives, nous pouvons formaliser les contextes donnant lieu à une action altruiste formellement et essayer de comprendre dans quel environnement un type d'altruisme apparaît plutôt qu'un autre, ou s'ils apparaissent simultanément. Pour cela, nous faisons appel à la théorie des jeux.

2.5 Lien à la théorie des jeux

La théorie des jeux est née de la nécessité de comprendre l'émergence des comportements altruistes dans la nature, en s'appuyant initialement sur la perspective géno-centrée, qui considère les gènes comme les véritables unités de sélection. Selon cette approche, seuls les traits favorisant la transmission des gènes sont sélectionnés, ce qui explique l'apparition de comportements altruistes via la sélection de parenté. Ce mécanisme, formalisé par la loi de Hamilton ($rb > c$), montre que les individus peuvent sacrifier leur propre fitness pour aider leurs proches, augmentant ainsi la propagation de leurs gènes communs. Cependant, la sélection de parenté ne suffit pas à expliquer toutes

les formes d'altruisme, notamment entre individus non apparentés. L'altruisme réciproque élargit alors le cadre de coopération, en montrant que des interactions répétées permettent de stabiliser la coopération par réciprocité, à condition que les individus puissent évaluer et se souvenir des comportements passés. Pour modéliser ces mécanismes, la théorie des jeux est utilisée, avec des jeux comme le dilemme du prisonnier, qui simulent les décisions entre coopération et égoïsme. Des travaux pionniers, comme les simulations de Robert Axelrod ou de Maynard Smith, ont démontré comment des stratégies comportementales concurrentes évoluent dans des contextes donnés, expliquant ainsi mathématiquement l'émergence et la stabilité de comportements altruistes, même parmi des individus initialement égoïstes [2]. Ainsi, la compétition de fitness entre agents permet de modéliser de l'altruisme biologique.

L'altruisme comportemental peut également être modélisé par des scénarios où les individus prennent des décisions impliquant des coûts pour eux-mêmes et des bénéfices pour autrui, sans attente en retour, que ce retour soit immédiat ou différé. La théorie des jeux permet d'explorer ces interactions à travers le *Dictator Game* ou le *Trust Game*, comme mentionnés à la Sous-section 2.2. Dans le jeu du dictateur, un individu (le « dictateur ») décide de partager (ou non) une somme d'argent avec un autre joueur. Toute décision de donner une partie des gains, même sans bénéfice attendu en retour, est considérée comme un comportement altruiste. Cela démontre que les individus, en moyenne, ne maximisent pas toujours leur propre profit, ce qui correspond à la définition de l'altruisme comportemental. Le jeu de la confiance, légèrement différent, traite de l'interaction entre deux joueurs. Le donneur décide d'envoyer une somme d'argent à un second joueur, appelé le récipiendaire. La somme est multipliée, et le récipiendaire peut alors choisir de renvoyer une partie de cette somme au premier joueur. Lorsque les participants prennent le risque de faire confiance, sans garantie que l'autre joueur agira en retour, ils manifestent un comportement altruiste. Ces comportements peuvent être étudiés à travers des matrices de gains, où les choix altruistes sont moins payants à court terme mais peuvent s'avérer avantageux dans des interactions répétées. Cela fait immédiatement penser à la stratégie *tit-for-tat* dans le dilemme du prisonnier, où la stratégie consiste à coopérer d'abord, puis copier exactement ce que l'adversaire a fait [3]. La théorie des jeux permettrait ainsi également de traiter des cas d'altruisme comportemental, même si cela est plus compliqué à simuler.

Il est plus compliqué de trouver dans la littérature des jeux permettant de mieux comprendre et modéliser le débat sur l'altruisme psychologique. Cependant, la théorie des jeux pourrait intégrer l'empathie ou le désir de coopération, qui sont des motivations internes et conscientes, en tenant compte de préférences subjectives et de dynamiques cognitives. Les modèles classiques comme le modèle du prisonnier supposent que les joueurs maximisent uniquement leur propres bénéfices (nombre de points final). Cependant, il serait intéressant d'introduire une dimension sociale, en intégrant par exemple l'aversion à l'inégalité, le souci du bien-être d'autrui ou encore l'effet des émotions qui est au cœur du débat de l'altruisme psychologique. Ainsi, un joueur pourrait accepter un coût personnel pour réduire les inégalités ou améliorer le bien-être collectif, ce qui reflète une motivation psychologique d'ordre altruiste. Il est important de noter que plus de paramètres sont ajoutés, moins les prédictions sont évidentes, car il devient difficile de déterminer la part de l'influence causale de chacun de ces paramètres. Ainsi, essayer de répondre à ce débat par la théorie des jeux semble plus compliqué pour cette notion d'altruisme, même si un lien évident peut en être tiré.

2.6 Travaux connexes

Nos travaux s'inscrivent dans un domaine de recherche en pleine effervescence : l'émergence de comportements sociaux complexes dans des environnements multi-agents. Deux contributions majeures de l'équipe de DeepMind permettent de mieux situer notre approche et de justifier nos inspirations, tout en mettant en lumière des pistes que nous aurions pu explorer ou approfondir davantage.

Dans leur article *Multi-agent Reinforcement Learning in Sequential Social Dilemmas* [4], Leibo

et al. remettent en question la modélisation classique des dilemmes sociaux à l'aide de jeux matriciels (comme le dilemme du prisonnier), en montrant qu'ils ne suffisent pas à capturer la complexité des interactions séquentielles du monde réel. À la place, ils introduisent la notion de dilemme social séquentiel (SSD), où les comportements coopératifs ou défecteurs ne sont pas des actions simples, mais des politiques entières, c'est-à-dire des stratégies à long terme apprises au fil de l'expérience.

Cette distinction aurait pu enrichir notre propre approche, notamment en proposant une lecture plus fine des actions de l'agent autonome. Par exemple, dans nos simulations, un agent qui donne de la fitness à un autre peut être vu comme "coopératif", mais cette action isolée ne constitue pas forcément une politique de coopération à long terme. En intégrant une analyse de politiques comme dans Leibo et al., nous aurions pu mieux qualifier la nature sociale des comportements émergents et distinguer plus rigoureusement les tendances coopératives opportunistes des stratégies véritablement altruistes.

De plus, leur méthodologie d'analyse empirique des matrices de gains issues de politiques opposées (coopération vs défection) aurait pu nous fournir un cadre d'évaluation systématique pour classer les dynamiques émergentes dans notre propre environnement de grille, à l'image de leur distinction entre les jeux "Gathering" et "Wolfpack".

L'article *Emergent Bartering Behaviour in Multi-Agent Reinforcement Learning* [5] explore comment, sans instructions explicites, des agents peuvent apprendre à échanger des ressources lorsqu'ils sont entraînés dans un cadre suffisamment expressif. Ce résultat met en évidence la capacité des environnements multi-agents à faire émerger des formes d'organisation sociale spontanée, dès lors que les mécanismes d'interaction sont riches et suffisamment incitatifs. Ce travail aurait pu nous inspirer sur les points suivants.

Tout d'abord, la richesse de l'environnement mise en place au sein de cette étude est très complète. Leur simulation intègre des ressources distinctes, des préférences différenciées et un espace d'action plus diversifié. Introduire une telle complexité dans notre propre modèle, par exemple en introduisant la notion de ressource ou en ajoutant une mécanique d'échange, aurait pu rendre l'émergence de comportements altruistes plus significative, en incluant des formes de don ou de troc plus réalistes. Cependant, comme il sera précisé plus tard, l'objectif n'est pas de simuler une situation réaliste, mais plutôt d'analyser l'émergence de stratégies altruistes au sein de diverses populations.

Ensuite, la notion de coopération instrumentale est très intéressante. Le troc émerge dans leur étude comme un compromis stratégique, sans motivation morale. Cela aurait pu alimenter notre réflexion sur l'altruisme comportemental, qui, comme expliqué auparavant, n'est pas évident à lier à la théorie des jeux ou aux simulations informatiques.

Enfin, simuler l'économie sociale apporte une nouvelle dimension et ouvre la voie vers une modélisation plus économique que biologique ou psychologique de l'altruisme, en mettant en scène des agents qui échangent plutôt que de simplement donner ou attaquer. Cela pourrait élargir notre cadre vers une simulation des fondements de la coopération économique.

3 Méthodologie : Simulation informatique de l'altruisme

3.1 Présentation du modèle de simulation

3.1.1 Définition de l'environnement

L'environnement de notre simulation prend la forme d'une grille bidimensionnelle de 20x20 cases, représentant un espace clos où interagissent plusieurs populations distinctes, décrites précisément plus tard. Dans la Fig.(1), trois populations distinctes sont représentés en rouge, vert et bleu.

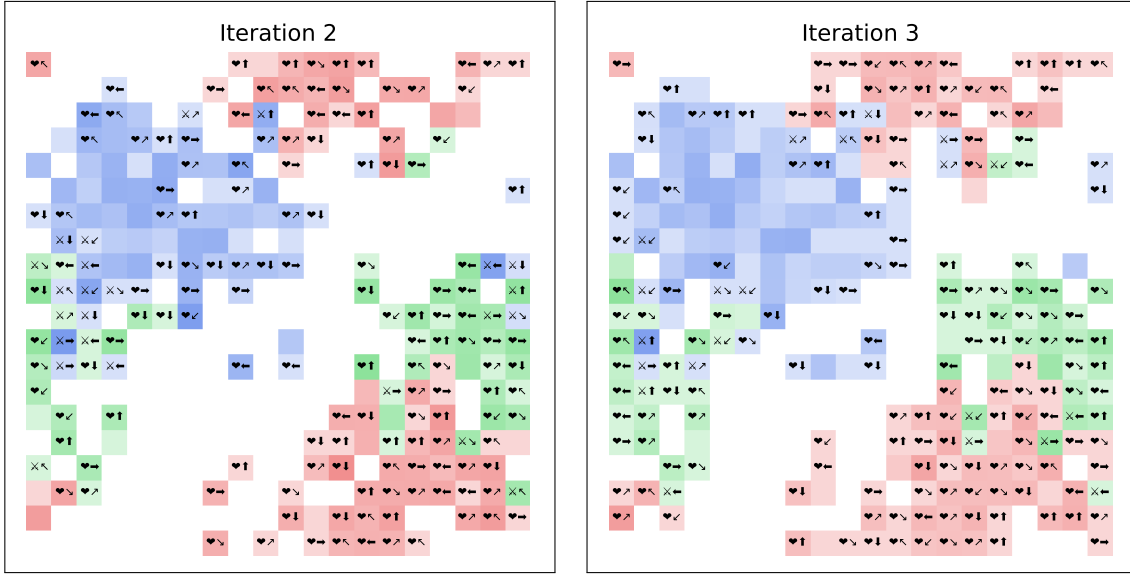


Figure 1: Environnement de la simulation à la 2^e puis à la 3^e itération avec agents "giving" en rouge, "attacking" en bleu et "complete" en vert dans une grille 20x20.

Chaque case peut potentiellement être occupée par un agent, et les conditions de bord sont périodiques, c'est-à-dire que les actions passant par un bord agissent à l'opposé de la grille. Cela permet ainsi de supprimer les potentiels effets de bord, qui pourraient fausser les comportements émergents des différents agents. Comme il est possible de le voir sur la Fig.(1), l'action qui a été réalisée par chaque agent lors de la dernière itération est visible. Les flèches en gras représentent la direction des actions, et les cœurs et les épées représentent les donations et les attaques, respectivement. Si aucun symbole ne figure sur une case, cela signifie que l'agent a décidé de ne rien faire. Les cases blanches représentent les cases non-occupées, et les cases colorées ont différentes intensités de couleur; plus la case est foncée, plus l'agent possède de fitness. En-dessous d'un certain seuil de fitness, l'agent disparaît et la case devient blanche.

Les populations sont initialisées selon des distributions gaussiennes centrées aléatoirement sur la grille, ce qui favorise la formation naturelle de clusters. À l'intérieur de ces clusters, les niveaux de fitness des agents (leur valeur sélective) suivent également une distribution normale, ce qui permet d'introduire la notion d'hétérogénéité au sein d'une même population, rendant ainsi la simulation plus réaliste. Pour ce faire, la fitness moyenne a été fixée à une valeur de 1, pour un écart-type de 0,2.

Les agents ont trois possibilités à chaque nouvelle itération. Ils peuvent ne rien faire, attaquer, ou donner. Dans le cas d'une donation, 20% de la fitness de l'agent en question lui est enlevée et est distribuée à l'agent dans la direction choisie. Par ailleurs, les agents peuvent choisir d'attaquer une cellule voisine. Dans ce cas, la fitness la plus petite entre les agents du duel est soustraite à la fitness des deux agents. Cela implique que l'agent ayant la fitness la plus petite meurt, et l'autre subi des dégâts à la hauteur de l'agent éliminé. Finalement, la fitness originale de l'agent tué est redistribuée équitablement parmi les cellules voisines. Par exemple, si l'agent A ayant une fitness de 0.5 attaque l'agent B qui a une fitness de 0.8, alors l'agent A meurt et l'agent B se retrouve à 0.3 de fitness. Ensuite, la fitness de l'agent A avant l'attaque (0.5) est redistribuée équitablement aux cellules voisines.

Il existe également deux autres paramètres que nous avons fait varier durant nos simulation; le bonus de donation et la croissance. En effet, ces deux paramètres ont une grande influence sur l'issue des résultats. Ainsi, l'environnement n'est pas figé et les conditions d'émergence de comportements altruistes peuvent être analysées plus précisément.

Le bonus de donation est un pourcentage bonus que la cellule qui reçoit une donation obtiendra. Par exemple, si ce bonus est de 4%, alors une cellule recevra 24% du fitness de son donateur, mais ce dernier n'en perdra que 20%. Ce paramètre sert à modéliser des cas réels d'altruisme ou l'action

altruiste à souvent bien moins d'effet négatif sur le donateur que d'effet positif sur celui qui reçoit. Ce paramètre a été varié entre 0 et 8% (0%, 4% et 8%).

Un problème que nous avons observé est que le nombre de fitness disponible est limité et fixé à l'initialisation (du moins sans bonus de donation). De ce fait, les nouvelles cellules sont de plus en plus faibles et peinent à peupler toute la grille de départ. Afin de pallier à ce problème nous avons défini le paramètre de croissance. Ce dernier est un nombre absolu de fitness que toutes les cellules de la grille reçoivent à chaque itération. Ce paramètre peut être vu comme la croissance de chaque individu de l'environnement; ils deviennent un peu plus fort à chaque nouvelle itération. Cela permet de contrer le problème des individus devenant de plus en plus faibles. Ce paramètre a été varié entre 0 et 0,08 (0, 0,04 et 0,08), et représente une quantité de fitness en valeur absolue. Au départ, le coût pour occuper une nouvelle case était nul. Par la suite, comme détaillé dans la Section 4.1, cela a été modifié de sorte à ce qu'un agent doive faire une donation sur une case vide pour créer un nouvel agent et répandre la population sur la grille.

3.1.2 Introduction des agents

Trois types d'agents ont été conçus pour explorer différents niveaux de complexité comportementale :

- **Agents complètement aléatoires** : Ces agents agissent sans distinction d'allié ou d'ennemi, choisissant leurs actions (attaque, donation, inaction) de manière aléatoire parmi l'ensemble des possibilités. Ne pouvant pas faire de choix stratégiques, ils servent de base de comparaison pour les comportements plus stratégiques.
- **Agents semi-aléatoires** : Ces agents suivent des règles simples imitant un comportement partiellement stratégique, où "semi-aléatoire". Ils n'attaquent que des agents d'autres populations ou réservent leurs dons de "fitness" exclusivement à leurs alliés, renforçant ainsi la coopération au sein d'une même population. Il existe trois types d'agents semi-aléatoires; ceux qui ne font que des donations à leurs alliés (*Giving*), ceux qui ne font qu'attaquer les ennemis (*Attacking*), et les *Compleat*, qui donnent à leurs alliés ou qui attaquent leurs ennemis de façon aléatoire.
- **Agent intelligent** : Ce type d'agent représente la base de notre investigation, utilisant un algorithme d'apprentissage par renforcement (Reinforce [6]) pour maximiser sa "fitness" cumulative à travers le temps. Les récompenses sont attribuées en fonction des variations de fitness dans les cellules occupées, et des pénalités sont infligées si la population à laquelle il appartient disparaît, incitant ainsi les agents à converger vers une stratégie optimale. La définition de cette convergence est explicitée plus tard.

3.2 Paramètres de simulation et apprentissage de l'agent autonome

Pour simuler des comportements proches de l'altruisme, nous avons conçu un système dans lequel les agents apprennent à interagir avec leur environnement de manière stratégique. L'agent principal, que nous appelons "intelligent", fonctionne grâce à un algorithme de reinforcement learning [6], basé sur le principe de la récompense et de la punition. Concrètement, cet agent effectue des actions, comme se déplacer, attaquer un autre agent, ou donner une partie de sa propre "fitness", et reçoit une récompense ou une pénalité en fonction des conséquences de ses choix. L'objectif de cet agent est de maximiser sa récompense à long terme. Par exemple, s'il donne une partie de sa fitness à un agent allié et que cela renforce sa population au cours des itérations suivantes, il peut en bénéficier indirectement dans le futur et apprendre à effectuer la bonne action dans une situation donnée déjà rencontrée. À l'inverse, s'il agit de façon désordonnée et affaiblit sa propre population, il sera pénalisé et en tirera des leçons. L'agent autonome apprend donc grâce à un réseau de neurones, entraîné par essais et erreurs : à chaque simulation, il teste

des actions, en observe les résultats, et ajuste ses futures décisions en conséquence. Le réseau de l'agent autonome est composé de deux couches linéaires, séparées par des fonctions d'activation ReLU et une régularisation par dropout. Ce processus est encadré par plusieurs paramètres, décrits ci-dessous:

- Taux d'apprentissage qui contrôle la vitesse à laquelle l'agent ajuste ses stratégies: 0,001.
- Facteur de réduction qui valorise les récompenses que l'agent prédit obtenir dans un futur proche plutôt que lointain: 0,98.
- Batch size: 50 (l'agent apprend à partir de 50 expériences simultanément).
- Taille de grille: 20x20 cases.

Les choix de l'agent (attaquer, donner, ne rien faire) sont décidés parmi plusieurs options possibles, et leur probabilité est ajustée par l'algorithme au fil du temps. Une méthode appelée "régularisation par entropie" est utilisée pour encourager l'agent à ne pas se fixer trop rapidement sur une seule stratégie, en continuant à explorer d'autres possibilités pendant l'entraînement. Cela permet de converger vers une stratégie après avoir analysé plusieurs possibilités, et d'ainsi éviter une convergence immédiate. L'algorithme Reinforce est utilisé pour trouver une stratégie optimale. Cet algorithme est simple à implémenter, mais est connu pour être difficile à faire converger. Lors de nos essais, nous avons remarqué que d'ajouter la régularisation par entropie a permis à Reinforce de converger plus facilement, ou en d'autres termes, de trouver une solution plus souvent et plus rapidement. De plus, nous avons ajouté certains éléments de l'algorithme "Proximal Policy Optimization" (PPO) [7], comme "Gradient Weight Clipping", pour faciliter la convergence de l'apprentissage.

La convergence de l'apprentissage est observée à travers deux indicateurs principaux : la stabilisation des récompenses cumulées au fil des épisodes, et la diminution progressive de la "policy loss", qui est ce que l'on cherche à minimiser pendant l'entraînement de l'agent. Lorsque ces deux mesures atteignent un plateau stable, nous considérons que l'agent a acquis une stratégie cohérente dans l'environnement donné.

3.3 Hypothèses et limites du modèle

L'altruisme biologique fait référence à des comportements qui, bien que coûteux pour l'individu, augmentent les chances de survie de sa lignée génétique ou de son groupe d'appartenance. Ce type d'altruisme peut être modélisé dans notre simulation : les agents semi-aléatoires donnent de la fitness uniquement à leurs semblables, ce qui favorise la survie collective. De même, l'agent autonome peut apprendre à renforcer les agents de son propre groupe si cela améliore indirectement sa propre performance. Ainsi, un équivalent fonctionnel de l'altruisme biologique émerge dans le cadre de la simulation, bien qu'il ne repose pas sur une transmission génétique réelle.

L'altruisme comportemental se manifeste par des actions qui nuisent à l'individu sans aucun bénéfice attendu en retour. Or, notre agent autonome est formé à maximiser sa récompense cumulative : toute action entreprise a pour but, explicite ou implicite, d'augmenter sa propre "fitness". Il n'est donc pas possible, dans notre cadre, d'observer un comportement qui serait purement altruiste au sens comportemental strict, c'est-à-dire détaché de toute forme d'intérêt personnel, même différé. La question se pose pour les agents semi-aléatoires, où les agents prennent des décisions sans pour autant espérer un bénéfice en retour. En effet, en attaquant un agent d'une autre population, il ne sait pas si son "sacrifice" de fitness profitera à sa population ou à lui-même, n'ayant pas été entraîné pour réaliser cette action.

Comme expliqué précédemment (Section 2.5), il est compliqué de lier l'altruisme psychologique à la théorie des jeux, ou bien dans notre cas, à des simulations informatiques. L'altruisme psychologique implique une intention interne d'aider autrui, motivée par des émotions telles que le

désir ou l'empathie. Ce type d'altruisme suppose une forme de conscience de soi et d'autrui, absente dans notre cadre de simulation. Nos agents ne sont ni conscients, ni empathiques ; leurs actions sont entièrement orientées par des calculs d'utilité. Même lorsqu'un agent agit en faveur d'un autre, cela résulte d'une stratégie visant un gain futur, et non d'un souci sincère pour le bien-être d'autrui. Par conséquent, nos simulations ne peuvent pas rendre compte de l'altruisme psychologique, qui repose sur des états mentaux subjectifs que nos agents ne possèdent pas.

Au-delà des limites conceptuelles liées aux types d'altruisme, notre modèle repose sur des hypothèses techniques qui influencent la portée et la validité des résultats.

L'univers simulé est une grille bidimensionnelle de 20x20 cases. Il s'agit d'une simplification extrême du monde réel, où les agents n'interagissent qu'avec leur environnement immédiat (leurs voisins directs), il n'y a ni ressources naturelles, ni changements dynamiques du terrain, ni incertitude autre que celle intégrée à leurs décisions. Cette simplification est nécessaire pour rendre le problème techniquement solvable, mais elle limite la complexité des stratégies et la diversité des comportements possibles. Par exemple, la coopération complexe, la réputation ou la transmission culturelle sont absentes. L'objectif n'est cependant pas de s'approcher de la réalité et de montrer la potentielle émergence de l'altruisme, car dans ce cas, il faudrait plutôt observer et discuter des cas rencontrés dans la nature. Ici, la simulation a pour but d'observer si des comportements d'altruisme biologique ou comportemental peuvent émerger face à différents types de population simplifiées, et si oui, les stratégies adoptées.

Les agents sont initialement répartis selon des distributions gaussiennes centrées aléatoirement sur la grille, et leur niveau de fitness varie selon une autre distribution normale. Cette méthode favorise la formation de groupes et simule une certaine hétérogénéité. Toutefois, elle impose aussi une structure stable dès le départ, ce qui pourrait favoriser artificiellement la coopération au sein d'un groupe. On pourrait se demander si une distribution plus chaotique changerait les stratégies optimales acquises par les agents autonomes.

Le facteur de réduction joue un rôle fondamental dans la logique d'apprentissage. Il influence les récompenses futures, car plus il est proche de 1, plus l'agent accorde de l'importance aux bénéfices de long terme, et plus il est faible, plus il privilégie les gains immédiats. Le choix de 0,98 traduit une volonté de favoriser les stratégies à long terme. Ainsi, les actions qui n'apportent un bénéfice qu'à court terme sont automatiquement désavantagées. Cela confirme ce qui a été dit auparavant, c'est-à-dire que de l'altruisme comportemental ne peut pas être observé pour les agents autonomes dans le cadre de cette simulation, car un bénéfice à court terme est la définition même de l'altruisme comportemental, aussi appelé "altruisme désintéressé". En variant ce paramètre, cela contribuerait à conserver les comportements réellement altruistes au sens strict, qui n'offrent aucun retour sur investissement, même différé, mais cela augmenterait la probabilité d'une convergence immédiate, sans exploration de toutes les possibilités. Or, dans le cadre de ce travail, la stratégie altruiste émergente est recherchée.

Enfin, l'algorithme Reinforce utilisé est un algorithme classique de l'apprentissage par renforcement, qui suppose que les récompenses sont disponibles et mesurables à chaque étape. De plus, cet algorithme requiert l'hypothèse de Markov [8] qui postule que l'état futur dépend uniquement de l'état actuel et de l'action présente, et non de l'histoire passée. La première hypothèse n'est pas neutre, car elle empêche les agents de prendre une action dont l'utilité serait morale ou symbolique. De plus, comme précisé auparavant, l'altruisme psychologique n'est ainsi pas représenté, car les intentions internes ne sont pas motivées par des émotions, mais par des calculs quantifiables.

4 Résultats

4.1 Problèmes rencontrés

Lors de l'obtention des premiers résultats, un problème est survenu lors des duels des agents intelligents contre les semi-aléatoires, mais également pour le cas de figure détaillé ci-dessous. Comme expliqué précédemment, dans une première version, cela ne coûtait rien à un agent de peupler une nouvelle case. Ainsi, le comportement des agents intelligents est le suivant: occuper une case, attendre qu'une case voisine se fasse tuer pour recevoir une partie de la fitness redistribuée, et repeupler gratuitement la case. Les résultats de cette situation peuvent être visualisés sur la Fig.(3a).




Figure 2: Résultats du combat entre populations qui donnent (rouge), qui attaquent (bleu), et aléatoires (vert).

Comme il est possible de l'observer sur la Fig.(3a), ce problème mène à des cases vides entourées d'agents possédant beaucoup de fitness. En attendant en deuxième ligne derrière un combat, les populations accumulent de la fitness, qui croît exponentiellement, comme le montre la Fig.(3b). La population aléatoire, qui n'établit pas de stratégie, ne se développe pas du tout. Ce comportement a également été observé chez les agents intelligents, signifiant qu'ils ne performant pas comme espéré dans cet environnement. Attribuer un coût à l'occupation d'une case a réglé ce problème et a permis d'obtenir les résultats exposés à la section suivante.

4.2 Agent intelligent vs semi-aléatoire

L'agent autonome, appelé "agent intelligent", a combattu contre deux types d'agents semi-aléatoires: les agents giving et attacking. Afin d'observer l'évolution de la stratégie des agents intelligents, le bonus de donation de croissance ont été variés, comme expliqué dans la méthodologie de ce travail.

4.2.1 Agent intelligent vs giving

Pour commencer, une population d'agents intelligents a combattu contre deux populations d'agents semi-aléatoires ne faisant que des donations, appelés "giving". Les résultats obtenus, en faisant varier le bonus des dons et de croissance, sont représentés dans le tableau suivant:


Table 1: Répartition des fitness des différentes population en % et fitness totale en fonction des bonus de donation et de croissance pour une population d'agents intelligents contre deux populations d'agents semi-aléatoires "giving", avec en gras la population ayant le plus de fitness à la dernière itération de la simulation.

	Population	Bonus donation[%]/croissance[-]								
		0/0	0/0,04	4/0	4/0,04	8/0	8/0,04	0/0,08	4/0,08	8/0,08
Fitness[%]	Agent intelligent	42,23	67,41	36,93	21,66	7,12	3,39	73,26	16,06	2,71
	Giving	28,97	16,91	28,13	41,12	40,70	42,08	13,79	45,59	43,93
	Giving	28,80	15,68	34,94	37,22	52,18	54,53	12,95	38,35	53,36
Fitness totale		104,50	4471,60	466,36	31867,81	3,43e12	1,17e14	6610,87	58351,46	2,76e14


Les agents intelligents arrivent à trouver une stratégie gagnante contre les agents giving, tant que le bonus de donation reste faible. Les agents giving semblent également être légèrement favorisés par un bonus de croissance à chaque itération.

La distribution finale des populations, ainsi que l'évolution des trois populations au cours des itérations, peut être visualisée pour chaque simulation, avec un certain bonus de donation et de croissance. Par exemple, pour un bonus de donation de 4% et un bonus de croissance de 0,04, les résultats suivants ont été obtenus:

Exemple de Distribution Finale des Populations



(a) Distribution finale de la population. Rouge: agents intelligents. Bleu et vert: agents semi-aléatoires "giving".



(b) Evolution des trois populations au cours des itérations.

Figure 3: Résultats du combat agent intelligent vs giving vs giving.

Les distributions et graphiques ne sont pas présentés pour chaque rapport de bonus don/croissance pour éviter un surplus d'informations, mais seront analysés et discutés dans la discussion pour ceux qui apportent des informations supplémentaires.

4.2.2 Agent intelligent vs attacking

Les agents intelligents ne gagnent que lorsque le bonus de croissance est de zéro. Dès que ce dernier n'est pas nul, les agents intelligents ne trouvent pas de stratégie gagnante face aux agents attacking.

Table 2: Répartition des fitness des différentes populations en % et fitness totale en fonction des bonus de donation et de croissance pour une population d'agents intelligents contre deux populations d'agents attaquants.

	Population	Bonus donation[%]/croissance[-]								
		0/0	0/0,04	4/0	4/0,04	8/0	8/0,04	0/0,08	4/0,08	8/0,08
Fitness[%]	Agent intelligent	34,69	5,57	34,28	5,11	33,84	4,96	2,32	2,42	2,12
	Attacking	32,51	49,91	32,70	46,76	32,92	47,73	47,05	49,17	44,90
	Attacking	32,80	44,52	33,02	48,12	33,23	47,31	50,63	48,42	52,98
Fitness totale		124,17	10746,65	152,84	10834,52	206,60	10670,33	20692,76	20656,42	20718,66

4.3 Agent intelligent vs aléatoire

Quelque soit le rapport bonus de donation/croissance, les agents intelligents battent les agents aléatoires. Cependant, les agents aléatoires s'en sortent légèrement mieux dès qu'un bonus de croissance est instauré.

Table 3: Répartition des fitness des différentes population en % et fitness totale en fonction des bonus de donation et de croissance pour une population d'agents intelligents contre deux populations d'agents aléatoires, avec en gras la population ayant le plus de fitness à la dernière itération de la simulation.

	Population	Bonus donation[%]/croissance[-]								
		0/0	0/0,04	4/0	4/0,04	8/0	8/0,04	0/0,08	4/0,08	8/0,08
Fitness[%]	Agent intelligent	40,48	35,75	40,18	35,64	40,10	35,56	35,68	35,44	35,48
	Aléatoire	30,61	35,05	30,78	35,05	31,01	35,00	35,06	34,96	34,95
	Aléatoire	28,92	29,20	29,04	29,32	28,89	29,44	29,27	29,60	29,57
Fitness totale		88,35	6197,86	97,08	6260,44	109,98	6275,02	10771,16	10978,21	11159,79

4.4 Semi-aléatoire contre aléatoire

Chaque type d'agent semi-aléatoire a combattu contre les agents aléatoires, afin d'observer leurs comportements et leurs stratégies.

4.4.1 Giving vs aléatoire

Les agents giving gagnent toujours contre les agents aléatoires. Cependant, lorsque le bonus de croissance est nul, tous les agents de la grille s'affaiblissent rapidement et disparaissent.

Table 4: Répartition des fitness des différentes population en % et fitness totale en fonction des bonus de donation et de croissance pour une population d'agents semi-aléatoires ne faisant que des donations ("giving") contre deux populations d'agents aléatoires, avec en gras la population ayant le plus de fitness à la dernière itération de la simulation.

	Population	Bonus donation[%]/croissance[-]								
		0/0	0/0,04	4/0	4/0,04	8/0	8/0,04	0/0,08	4/0,08	8/0,08
Fitness[%]	Giving	0	41,11	0	41,17	100	41,26	41,09	41,16	41,28
	Aléatoire	0	29,44	0	29,42	0	29,37	29,46	29,42	29,36
	Aléatoire	0	29,44	0	29,42	0	29,37	29,46	29,42	29,36
Fitness totale		0	181,18	0	206,02	1,60e6	239,13	361,00	411,46	479,07

4.4.2 Attacking vs aléatoire

Ici, le même scénario est retrouvé. Les agents attacking battent constamment les agents aléatoires, dès que le bonus de croissance n'est pas nul (disparition de tous les agents).

Table 5: Répartition des fitness des différentes population en % et fitness totale en fonction des bonus de donation et de croissance pour une population d'agents semi-aléatoires ne faisant qu'attaquer("attacking") contre deux populations d'agents aléatoires, avec en gras la population ayant le plus de fitness à la dernière itération de la simulation.

	Population	Bonus donation[%]/croissance[-]								
		0/0	0/0,04	4/0	4/0,04	8/0	8/0,04	0/0,08	4/0,08	8/0,08
Fitness[%]	Attacking	100	41,64	100	41,85	100	42,14	41,67	41,87	42,12
	Aléatoire	0	29,18	0	29,07	0	28,93	29,16	29,07	28,94
	Aléatoire	0	29,18	0	29,07	0	28,93	29,16	29,07	28,94
Fitness totale		7,40e-07	187,89	2,48e-05	207,05	6,10e-04	231,29	375,11	413,72	463,48

4.4.3 Complet vs aléatoire

Une fois de plus, les agents semi-aléatoires sont meilleurs que les agents aléatoires, qu'importe les paramètres de donation et de croissance.

Table 6: Répartition des fitness des différentes population en % et fitness totale en fonction des bonus de donation et de croissance pour une population d'agents semi-aléatoires complets (giving + attacking) contre deux populations d'agents aléatoires, avec en gras la population ayant le plus de fitness à la dernière itération de la simulation.

	Population	Bonus donation[%]/croissance[-]								
		0/0	0/0,04	4/0	4/0,04	8/0	8/0,04	0/0,08	4/0,08	8/0,08
Fitness[%]	Complet	0	41,08	0	41,15	100	41,24	41,06	41,15	41,25
	Aléatoire	0	29,46	0	29,43	0	29,38	29,47	29,42	29,38
	Aléatoire	0	29,46	0	29,43	0	29,38	29,47	29,42	29,38
Fitness totale		0	181,03	0	206,09	1,46e06	238,32	362,54	411,18	478,41

4.5 Semi-aléatoire contre semi-aléatoire

Après avoir obtenu une base de comparaison des comportements des agents semi-aléatoires après les avoir fait combattre contre des agents sans stratégie, les trois types d'agents semi-aléatoires se sont affrontés.

4.5.1 Complet vs giving vs attacking

Lorsque le bonus de donation est important, les agents giving gagnent. Dans les autres situations, les agents attacking sont plus forts. Cependant, il a été observé que les résultats dépendent de l'initialisation des populations sur la grille. En effet, dans certaines situations, les agents complets ont gagné, ce qui ne se voit pas dans les résultats du tableau suivant:

Table 7: Répartition des fitness des différentes population en % et fitness totale en fonction des bonus de donation et de croissance pour les trois différentes populations d'agents semi-aléatoires (complet, giving, attacking), avec en gras la population ayant le plus de fitness à la dernière itération de la simulation.

	Population	Bonus donation[%]/croissance[-]								
		0/0	0/0,04	4/0	4/0,04	8/0	8/0,04	0/0,08	4/0,08	8/0,08
Fitness[%]	Complet	0	0	0,34	0,88	34,70	32,71	0	0,60	34,27
	Giving	0	0	0,39	0,80	65,30	67,29	0	0,49	65,73
	Attacking	100	100	99,27	98,32	0	0	100	98,91	0
Fitness totale		26,84	1,49e04	18,56	1,21e04	4,13e12	1,74e13	2,98e04	2,50e04	3,17e13

5 Discussion : Pertinence et implications des résultats

5.1 Analyse des résultats

5.1.1 Paramètres variés

Les résultats montrent une grande influence des paramètres "bonus de donation" et "bonus de croissance" sur les performances des différentes stratégies, comme discuté plus en détail dans les sections suivantes. Les agents attacking se répandent rapidement et bénéficient grandement de la croissance, alors que les agents giving (et complet) bénéficient du bonus de donation. Cependant, il est intéressant d'observer que ces deux paramètres semblent indépendants; dans les simulations où le bonus de croissance n'est pas nul, les agents attacking gagnent presque systématiquement, quels que soient leurs adversaires ou le bonus de donation. A l'inverse, dans les simulations avec un grand bonus de donation (supérieur ou égal à 8%), les agents giving l'emportent indépendamment de la croissance.

En réalité, ces deux paramètres ne sont pas complètement indépendants. Il est possible d'observer l'effet de leur corrélation dans les résultats de la simulation "agent intelligent vs giving" (Table 1). On observe que dans l'environnement avec un bonus de donation de 4% et une croissance de 0, l'agent intelligent gagne, alors que dans une simulation avec un bonus de donation de 4% et une croissance de 0.04, c'est l'agent giving qui gagne. Il semble alors que l'agent giving ait bénéficié de la croissance pour renforcer ses donations, ce qui lui a permis de remporter la simulation. Cette faible corrélation s'explique simplement par le fait que la croissance augmente la fitness de tous les individus, et augmentera donc légèrement la quantité absolue de fitness donnée (qui est un pourcentage de la fitness du donneur). Cependant, comme la fitness de tous les individus est augmentée, cette petite augmentation du bonus de fitness est souvent très faible et ses effets sont ainsi difficilement observables.

5.1.2 Agent intelligent vs semi-aléatoire

Les agents intelligents ont d'abord combattu contre les agents ne faisant que des donations. Dans cette configuration, deux populations distinctes d'agents "giving" affrontent une population d'agents intelligents. Les "giving" ne font que des dons de fitness à leurs propres membres, sans jamais attaquer, ni aider d'autres populations. Or, leur générosité interne non stratégique crée une situation propice à l'émergence d'un parasitisme stratégique : l'agent RL profite de la redistribution de fitness entre les "giving", qui les affaiblit. Ainsi, les agents intelligents font des donations de façon plus stratégique et tuent les agents giving, ayant une fitness plus élevée. Cependant, lorsque le bonus de donation est élevé ($\geq 4\%$), les agents giving surpassent les agents intelligents, quel que soit le bonus de croissance. Cela s'explique par une dynamique coopérative interne efficace chez les giving, où les dons circulent entre eux, renforçant leur fitness mutuelle. Les

agents intelligents, bien qu'adaptatifs, ne peuvent pas rivaliser avec cette solidarité efficace dans un environnement généreux. L'agent intelligent réussit à adopter une stratégie intéressante lorsque le bonus de croissance est nul:

Exemple de Distribution Finale des Populations



Figure 4: Distribution finale des populations lors du combat de l'agent intelligent contre giving, pour un bonus donation/croissance de 0%/0,04.

En effet, il est observable que les agents intelligents n'occupent pas forcément une grande partie de l'environnement, mais récoltent quand même une grande partie de la fitness totale (67,41%), grâce à quelques agents possédant énormément de fitness. Ces derniers accumulent de la fitness, et profitent de l'autodestruction des populations giving qui se donnent entre elles, affaiblissant leurs membres à chaque tour sans retour collectif. Ainsi, ils se contentent de récupérer la fitness par redistribution sans prendre de risques, jusqu'à devenir "imbattables". Pour cette raison, des cases rouges apparaissent plus foncées que les autres sur la Fig.(4).

Les agents "attacking" n'attaquent que les membres des autres populations, jamais leurs propres alliés. Ils constituent donc deux populations coordonnées autour d'un objectif défensif-offensif simple : affaiblir les autres populations. L'agent intelligent ne trouve une stratégie vainqueuse seulement lorsque le bonus de croissance est nul. Dans ce cas-là, les agents attacking, en s'attaquant mutuellement de façon prévisible, s'auto-détruisent souvent, ouvrant des opportunités aux intelligents pour se développer, peu importe les bonus environnementaux. Il est intéressant de noter qu'initialement, les agents intelligents perdent plus rapidement de la fitness que les agents giving, bien que le bonus de croissance soit nul:




Figure 5: Somme des valeurs sélectives par population pour agent intelligent vs attacking, pour un bonus donation/croissance de 4%/0.

Leur stratégie semblerait être de se répandre rapidement initialement, afin d'occuper une grande partie de la grille et récupérer de la fitness par la suite. Au début de la simulation, les attacking perdent moins de fitness, car ils attaquent les agents intelligents légèrement affaiblis, mais ils se retrouvent rapidement en infériorité numérique. Il est intéressant de noter la différence de stratégie adoptée par les agents intelligents; contre les giving, quelques agents accumulent de la fitness pour devenir imbattables et ne cherchent pas à se répandre, alors que contre les attacking, ils profitent de la supériorité numérique pour surprendre leurs ennemis. Toutefois, lorsque le bonus de croissance n'est pas nul, les attacking peuvent regagner rapidement la fitness perdue et maintenir leur pression offensive. Dans ces cas, les agents intelligents ne dominent pas systématiquement, notamment si leur apprentissage ne les amène pas à éviter efficacement les attaques. En effet, il semblerait que les agents intelligents soient incapables de fuir ou de réagir efficacement. Ils sont éliminés, même lorsqu'ils apprennent intelligemment à se positionner ou à économiser leur fitness. Chaque attaque diminue la fitness de l'attaquant et de l'attaqué, mais la coordination entre les attaquants leur permet d'amortir ce coût plus efficacement que l'agent intelligent, en l'encerclant et l'éliminant. Même entraînée, une population d'agents entraînés ne peut survivre à deux populations ennemies coordonnées et offensives dans un environnement où un agent reçoit de la fitness à chaque itération. De plus, il est important de noter que les agents intelligents ont été entraînés dans un environnement à bonus de croissance nul. Il serait intéressant d'observer si leur stratégie évoluerait en ayant été entraînés dans un environnement différent, ce qui serait sûrement le cas.

Lors du combat face aux agents aléatoires, les agents intelligents montrent leur supériorité claire dans tous les cas. Cela confirme que les agents intelligents ont bien été entraînés et qu'ils développent efficacement une stratégie. En effet, les agents aléatoires n'ayant pas de stratégie, ils représentent une bonne base de comparaison pour les comportements stratégiques des autres types d'agents. Les agents aléatoires n'ont pas de stratégie stable, ce qui permet aux intelligents d'apprendre à exploiter les configurations les plus avantageuses. Cette domination est légèrement moins marquée lorsque le bonus de croissance devient positif, car les agents aléatoires sont un peu plus "pardonnés" de leurs choix. Ils survivent un peu plus longtemps, sans pour autant changer l'issue du combat.

Il est intéressant de noter qu'il n'existe pas de lien entre les bonus de donation et de croissance. En effet, au-delà d'un certain bonus de donation, les agents intelligents n'arrivent plus à battre les giving, tout comme ils ne battent pas les attacking dès qu'un bonus de croissance est instauré, indépendamment de l'autre paramètre. De ce fait, il n'existe pas de ratio bonus de donation/croissance à partir duquel émerge une certaine stratégie gagnante.

5.1.3 Semi-aléatoire vs aléatoire

Lorsque la population "giving" affronte deux aléatoires, l'issue de la simulation dépend du bonus de croissance. Dès que ce dernier n'est pas nul, la population "giving" gagne assez largement. Lorsqu'un bonus de croissance est instauré, les agents semi-aléatoires possèdent en moyenne plus de fitness car ils font en quelques sortes des donations plus stratégiques sans se vider de leur fitness. Le nombre de dons diminuant, les pertes de fitness se réduisent et la population giving l'emporte. Cependant, lorsque le bonus de croissance est nul, les trois populations s'effondrent immédiatement, car les deux types d'agents s'affaiblissent et ne reçoivent pas de bonus entre chaque itération. Cela explique la fitness totale nulle dans les cas 0%/0 et 4%/0 du Tableau 4.

Sans surprise, la population attaquante domine totalement contre des populations aléatoires. Elle concentre ses attaques sur les ennemis, pendant que les aléatoires n'ont aucune stratégie. Une stratégie offensive et ciblée ainsi que la cohésion interne l'emportent sur l'absence de stratégie. Comme auparavant, la domination est moins marquée lorsqu'un bonus de croissance est instauré, donnant plus le droit à l'erreur aux agents aléatoires.

Les agents semi-aléatoires "complets" alternent entre donner et attaquer. Leur performance dépend, comme pour les agents attacking et giving, des bonus de croissance. Dès que ce dernier

n'est pas nul, l'agent complet l'emporte, comme il a été observé chez les agents qui donnent. Pour un bonus de croissance nul, leur générosité excessive les fragilise et ils privilégient visiblement les dons aux attaques, s'affaiblissant considérablement. Les résultats sont fortement similaires à ceux observés chez les agents giving.

En général, les différents types d'agents semi-aléatoires obtiennent les mêmes résultats face aux agents aléatoires. La base de comparaison d'un agent aléatoire sans choix stratégiques est utile pour voir si un comportement stratégique est développé chez l'ennemi, mais ne permet pas de discussion plus approfondie.

5.1.4 Semi-aléatoire vs semi-aléatoire

Ce scénario met en lumière les limites et les complémentarités des trois stratégies semi-aléatoires. Dans un scénario "giving" vs "attacking" vs "complet", la population "attacking" l'emporte dans la majeure partie des cas. Lorsque le bonus de donation est élevé (0,8), les agents giving peuvent tirer leur épingle du jeu, en formant des réseaux de coopération interne qui surpassent les attaques ponctuelles des autres. S'ils ne sont pas trop isolés, ils réussissent à maintenir une population stable, voire dominante. Les agents attacking tirent parti des environnements à plus faible croissance et bonus de donation, où leurs cibles ont du mal à récupérer leur fitness. Les agents complets n'émergent pas dans ces conditions qui favorisent soit les attacking, soit les giving. Un environnement intermédiaire, avec des valeurs bonus moins extrêmes pourraient favoriser leur émergence.

5.2 Liens entre altruisme biologique, comportemental et psychologique

Afin d'évaluer la portée des comportements observés dans les simulations, il est essentiel de les confronter aux trois définitions discutées dans le cadre théorique de l'altruisme: biologique, comportemental et psychologique.

L'altruisme biologique se définit comme un comportement qui, tout en coûtant à l'individu, augmente les chances de survie du groupe ou des apparentés génétiques. Dans nos simulations, ce type d'altruisme est partiellement modélisé. Les agents "giving" renforcent effectivement la résilience de leur groupe, notamment lorsque le bonus de donation est élevé. Toutefois, cette forme d'altruisme reste fragile face aux populations agressives, et n'est viable que dans des environnements peu compétitifs. Les agents attacking sacrifient leur fitness pour leur population et tirent parti des environnements à haute croissance. Quant à la population "intelligente", bien que motivée uniquement par des récompenses individuelles, elle peut apprendre à donner aux membres de sa population si cela maximise ses gains à long terme. Il ne s'agit pas d'un altruisme au sens moral, mais d'un altruisme fonctionnel, aligné avec les intérêts évolutifs collectifs. Cela s'apparente à des stratégies observées dans certaines espèces animales, où le sacrifice ponctuel d'un individu sert à la survie du groupe. L'altruisme biologique émerge sous certaines conditions, mais il reste dépendant de la structure de l'environnement. L'agent intelligent développe des stratégies gagnantes contre les agents giving, tant que le bonus de donation n'est pas trop important. En même temps, ces agents ont besoin d'un bonus de croissance nul contre les agents attacking. Cela révèle leur capacité à s'adapter à leur environnement, en adoptant différentes stratégies en fonction du type d'ennemi, une dynamique essentielle dans l'analyse de l'altruisme biologique : la distinction entre survie individuelle optimale et bénéfice collectif à long terme. La concentration extrême de la fitness dans les mains de quelques individus semble paradoxale. En effet, ils ne représentent pas une diffusion équitable de l'altruisme : ils forment un groupe à part entière, basant sa stratégie uniquement sur le fait de récolter un grand pourcentage de fitness, aux dépens des autres membres de la population. Ce résultat, en apparence pro-social, n'est pas nécessairement altruiste au sens biologique. Dans les combats contre les attacking, les agents intelligents tendent à diffuser leur fitness sur une plus grande population. Ils évitent les attaques directes, construisent des réseaux stables et s'étendent

géographiquement. Ce type de propagation favorise une résilience collective, ce qui se rapproche davantage de stratégies coopératives évolutives, dans lesquelles la survie du groupe prévaut sur la domination d'un seul. Ainsi, la première réponse obtenue dans ce travail révèle que l'altruisme émergerait dans des environnements agressifs, lorsque le coût d'une donation est plus faible que le gain pour le receveur. Sans cette dernière condition, les stratégies mises en places par les agents intelligents échouent clairement.

En biologie, cette situation correspond à des écosystèmes où l'aide apportée a un effet non linéaire : par exemple, une sentinelle qui prévient tout le groupe d'un prédateur permet à plusieurs individus de survivre, pour un coût maximal d'une seule vie. C'est le principe de l'altruisme indirect ou coopératif, dans lequel le retour sur don n'est pas immédiat mais passe par le maintien du groupe. En revanche, sans bonus de donation (ou avec un bonus faible), l'acte de donner est strictement perdant : le coût individuel n'est pas compensé par le gain du receveur, et donc la sélection naturelle tend à l'éliminer. Cela rejoint une idée bien connue : l'altruisme ne peut émerger sans structure incitative, que ce soit via un retour différé (réciprocité), un avantage de groupe, ou une amplification externe (comme ici avec le bonus de donation). Autrement dit, l'altruisme ne peut pas émerger "naturellement" sans condition environnementale favorable.

L'altruisme comportemental exige trois conditions : un coût pour l'agent, un bénéfice pour autrui, et aucune attente de retour. Les agents "giving" semblent remplir ces critères, puisqu'ils donnent de manière inconditionnelle à leurs semblables, sans anticipation de retour. Toutefois, ces agents n'ont aucune capacité d'intention : ils ne choisissent pas de donner, ils le font par simple programmation. Leur action n'est ni morale, ni calculée, ni contextuelle. Il s'agit d'une forme d'altruisme comportemental, mais seulement en apparence, car ces agents sont programmés pour réaliser une seule action, celle de donner. Il est cependant pertinent de se demander si le fait qu'un codeur ait programmé le comportement derrière ce type d'agent empêche l'émergence de l'altruisme, ce qui soulève une question centrale : peut-on réellement qualifier ces agents d'altruistes, alors que leur stratégie est codée a priori par un humain et exécutée sans intention propre ? Contrairement à un être humain qui choisit consciemment d'agir par altruisme, ou à un animal dont le comportement a été façonné par la sélection naturelle, les agents giving suivent une règle fixe, déterminée extérieurement. Ils n'ont ni conscience, ni objectif, ni capacité d'adaptation. Dès lors, leur comportement, bien qu'altruiste en apparence, ne relève pas d'un choix ni d'une pression évolutive interne. On pourrait les comparer à des robots programmés pour distribuer de la nourriture sans comprendre pourquoi. Cela pose la question suivante : l'altruisme peut-il exister sans liberté de choix, ni mécanisme d'ajustement évolutif ? Dans ce cadre, le véritable altruiste ne serait pas l'agent giving, mais potentiellement le concepteur qui a délibérément injecté un comportement sacrificiel dans un système, ou bien, l'environnement qui sélectionne ou non ces comportements selon leur efficacité populationnelle. Ce débat met en lumière la différence entre altruisme simulé et altruisme émergent, une distinction cruciale dans l'étude des comportements sociaux artificiels.

Les agents intelligents, en revanche, ne réalisent jamais d'actions réellement désintéressées. S'ils donnent, c'est uniquement lorsqu'ils y trouvent un avantage différé ou indirect. Un don sans attente en retour n'est donc pas compatible avec les agents intelligents, qui ne donnent que si ils y voient un avantage stratégique. Ainsi, l'altruisme comportemental peut apparaître en surface dans certains cas (agents giving ou attacking), mais il reste vidé de toute signification morale ou intentionnelle dans ce cadre simulationnel.

Si les agents intelligents ne peuvent pas être altruistes au sens comportemental, il est judicieux de se demander si les êtres humains peuvent l'être. En effet, pour vérifier si un bénéfice n'est pas obtenu sur le long terme ou si un espoir de recevoir un bénéfice n'arrive pas de façon différée, l'expérience doit être réalisée sur un intervalle correspondant au temps d'une vie, ce qui n'est jamais réalisé en pratique. Si on ne peut pas parler d'altruisme comportemental pour un être humain, ce type d'altruisme n'apparaît sûrement pas dans ces simulations informatiques.

Enfin, l'altruisme psychologique suppose une motivation interne à faire le bien d'autrui, sans contrainte extérieure, et sans profit personnel. Cette forme d'altruisme implique des états mentaux subjectifs : empathie, compassion, sens du devoir. Or, aucun des agents simulés ne dispose de représentation de soi ou d'autrui. Ils n'ont ni mémoire, ni empathie, ni conscience. Dans le

cas des agents giving, bien qu'ils adoptent un comportement répétitif de don, ils ne possèdent aucune représentation mentale, ni capacité émotionnelle. Ils ne donnent pas parce qu'ils "veulent" aider, mais parce qu'un code externe les y oblige. Il s'agit d'un automatisme algorithmique, et non d'un acte motivé. Dans ce sens, ils ne peuvent pas être considérés comme altruistes au sens psychologique, car ils n'éprouvent rien, ne délibèrent pas, et ne comprennent pas les conséquences de leurs actes. L'absence totale d'intentionnalité et d'émotion rend impossible toute attribution d'altruisme psychologique. Ce constat souligne une limite fondamentale des simulations, comme expliqué à la Section 3.3. Elles peuvent reproduire les effets d'un comportement humain sans en simuler les causes internes. Cela renforce la distinction entre comportement observable et motivation subjective, qui reste au cœur des débats sur la simulation de la moralité ou des émotions en intelligence artificielle.

5.3 Critique de la méthodologie

Malgré la richesse des dynamiques simulées, plusieurs limites doivent être reconnues, tant sur le plan conceptuel que technique.

Les bonus de croissance et de donation sont, comme le confirment les résultats, deux paramètres intéressants à varier, car ils ont une importante influence sur l'issue des résultats. De plus, ils ont un sens philosophique et n'ont pas été intégrés par hasard, comme expliqué dans la méthodologie de ce travail. Ici, ils ont été variés de sorte à ce que l'issue des résultats change. Il serait désormais important d'étudier leur pertinence, et de juger laquelle des deux valeurs extrêmes représente le plus la réalité.

Toutes les actions sont évaluées en termes de fitness immédiate ou différée. Cela exclut d'emblée toute forme d'action morale, gratuite, ou symbolique. L'émergence de l'altruisme, dans cette logique, ne peut exister que s'il rapporte, ce qui biaiserait les conclusions sur son émergence réelle.

De plus, plusieurs paramètres, observés dans la réalité, pourraient biaiser les résultats obtenus. Les notions de punition, de réputation, de mémoire sont souvent incluses dans les discussions philosophiques sur l'altruisme et ne figurent pas au sein des simulations. Cela simplifie les dynamiques au point de masquer les véritables conditions de la coopération humaine.

L'altruisme psychologique est inobservable ici car aucun agent ne possède de modèle de l'autre, ni de motivation interne. Cela pose la question philosophique : peut-on parler d'altruisme sans liberté, sans intention, sans conscience ? La simulation actuelle se limite à des calculs de fitness, excluant toute profondeur cognitive.

Enfin, comme observé dans les résultats, le choix des bonus (croissance, donation) oriente profondément les dynamiques. Un faible bonus de donation aurait empêché toute émergence de coopération chez les agents intelligents. Cela montre que l'altruisme n'émerge que sous certaines conditions fixées par l'environnement, ce qui encourage l'analyse des paramètres utilisés pour juger de leur pertinence.

6 Conclusion

Ce travail a exploré les conditions d'émergence de l'altruisme à travers un modèle informatique original fondé sur des agents évoluant dans un environnement discret. En opposant des populations d'agents intelligents entraînés par un algorithme de RL, semi-aléatoires et aléatoires, et en faisant varier des paramètres environnementaux cruciaux tels que le bonus de donation et le bonus de croissance, il a été possible de tester l'impact de différentes stratégies sur la survie, la diffusion, et le succès collectif des populations.

Les résultats montrent que l'altruisme peut émerger dans des contextes spécifiques, mais que cette émergence dépend fortement des conditions structurelles de l'environnement. Par exemple, les agents giving ne l'emportent que lorsque le système amplifie les bénéfices du don (bonus de donation élevé), tandis que les agents intelligents adaptent leur comportement à l'environnement et exploitent souvent les altruistes systématiques. Paradoxalement, leur victoire n'est pas toujours synonyme d'une stratégie véritablement altruiste : face aux agents attacking, leur comportement tend vers la coopération et la diffusion, alors que face aux giving, ils favorisent la concentration de fitness. Ce contraste suggère que l'altruisme efficace n'est pas nécessairement celui qui sacrifie, mais celui qui équilibre don et préservation.

L'analyse a également montré que les comportements observés, bien qu'altruistes en apparence, ne relèvent pas tous du même type d'altruisme. Les agents semi-aléatoires n'ont ni intentionnalité ni adaptabilité : leur comportement se rapproche de l'altruisme comportemental, voire d'un simple déterminisme sans profondeur cognitive. Ils ne peuvent en aucun cas incarner un altruisme psychologique, tous comme les agents intelligents, car ils sont dépourvus de motivation interne. Cela met en évidence une tension entre l'altruisme simulé et l'altruisme émergent, plus proche des processus évolutifs naturels.

Ce projet soulève enfin une question plus large : quelles sont les limites des simulations dans la modélisation du comportement social ? Si les algorithmes permettent de tester des hypothèses précises et de révéler certaines dynamiques non triviales, ils restent des abstractions qui négligent la richesse cognitive, émotionnelle et historique des comportements humains ou animaux. L'altruisme, en tant que phénomène biologique, social et psychologique, ne peut se réduire à une seule métrique ou stratégie. De plus, des algorithmes plus complexes permettraient de mieux entraîner les agents intelligents, questionnant la limite de modélisation des comportements sociaux et l'étude des stratégies émergentes.

Ce travail se veut avant tout une base expérimentale pour l'étude de l'émergence de stratégies altruistes dans des environnements simulés. Il pose des fondations simples mais extensibles, en montrant comment des règles de base et des interactions localisées peuvent conduire à des dynamiques collectives complexes. Néanmoins, il est clair que les algorithmes utilisés ici peuvent être approfondis, en particulier du côté des agents intelligents, pour explorer des comportements plus fins, adaptatifs et contextuels. De même, les paramètres fixés dans les simulations peuvent être variés ou raffinés pour tester d'autres conditions écologiques ou sociales. L'objectif n'est pas de figer un modèle, mais d'ouvrir un cadre modulable permettant d'approfondir, étape par étape, la compréhension computationnelle de l'altruisme sous ses multiples formes.

References

- [1] CLAVIEN Christine. *Je t'aide...moi non plus*. Philosophie des sciences. Vuibert, 2010. ISBN: ISBN 978-2-311-00049-8.
- [2] Bruno BEAUFILS. "Modèles et simulations informatiques des problèmes de coopération entre agents". In: *Doctoral Thesis* (2009), pp. 1–6. DOI: <https://theses.hal.science/tel-00366446v1>.
- [3] AXELROD. *The evolution of cooperation*. Basic Books, 1984.
- [4] Leibo Joel et al. "Multi-agent Reinforcement Learning in Sequential Social Dilemmas". In: *Proceedings of the 16th International Conference on Autonomous Agents and Multiagent Systems (AAMAS 2017)* (2017), pp. 464–473. DOI: 10.5555/3091125.3091194.
- [5] Johanson Mike, Hughes Edward, and Leibo Joel. *Emergent Bartering Behaviour in Multi-Agent Reinforcement Learning*. URL: <https://deepmind.google/discover/blog/emergent-bartering-behaviour-in-multi-agent-reinforcement-learning/>. (accessed:23.04.2025).
- [6] Ronald J. Williams. "Simple statistical gradient-following algorithms for connectionist reinforcement learning". en. In: *Machine Learning* 8.3 (May 1992), pp. 229–256. ISSN: 1573-0565. DOI: 10.1007/BF00992696. URL: <https://doi.org/10.1007/BF00992696> (visited on 04/28/2025).
- [7] John Schulman et al. *Proximal Policy Optimization Algorithms*. arXiv:1707.06347 [cs]. Aug. 2017. DOI: 10.48550/arXiv.1707.06347. URL: <http://arxiv.org/abs/1707.06347> (visited on 04/28/2025).
- [8] "Generators and Markov Processes". en. In: *Markov Processes*. John Wiley & Sons, Ltd, 1986, pp. 155–274. ISBN: 978-0-470-31665-8. DOI: 10.1002/9780470316658.ch4. URL: <https://onlinelibrary.wiley.com/doi/abs/10.1002/9780470316658.ch4> (visited on 04/28/2025).